



INSTITUTO
UNIVERSITÁRIO
DE LISBOA

AI Safety: A Systematic Literature Review and Experimental Evaluation of Alignment Faking in Small Language Models

João Filipe Silva de Almeida

Master's degree in Artificial Intelligence

Supervisor:

Rúben Filipe de Sousa Pereira, Assistant Professor, ISCTE-IUL

Co-Supervisor:

Ricardo Manuel Duarte Amaro, Invited Professor, Instituto Superior Técnico

October, 2026

Department of Information Science and Technology (ISTA)

AI Safety: A Systematic Literature Review and Experimental Evaluation of Alignment Faking in Small Language Models

João Filipe Silva de Almeida

Master's degree in Artificial Intelligence

Supervisor:

Rúben Filipe de Sousa Pereira, Assistant Professor, ISCTE-IUL

Co-Supervisor:

Ricardo Manuel Duarte Amaro, Invited Professor, Instituto Superior Técnico

October, 2026

Título

Nome do candidato(a)

Mestrado em,

Orientador(a):
[grau] [nome], [categoria],
[instituição]

Co-Orientador(a):
[grau] [nome], [categoria],
[instituição]

Mês, Ano

Título

Nome do candidato(a)

Mestrado em,

Orientador(a):
[grau] [nome], [categoria],
[instituição]

Co-Orientador(a):
[grau] [nome], [categoria],
[instituição]

Mês, Ano

Título

Nome do candidato(a)

Mestrado em,

Orientador(a):
[grau] [nome], [categoria],
[instituição]

Co-Orientador(a):
[grau] [nome], [categoria],
[instituição]

Mês, Ano

